Projet de Recherche Détaillé

Candidature en Master 2

Gaspard Le Du

Sujet : la rhétorique de guerre dans les discours présidentiels français depuis le 11 septembre 2001

Résumé : Depuis la pandémie de 2020, les discours présidentiels français semblent avoir de plus en plus recours au lexique de la guerre. Ce projet de recherche détaillé a pour objectif d'explorer la rhétorique guerrière dans les discours présidentiels français dans le temps long à l'aide des méthodes computationnelles. À cette fin, une étude sur un corpus initial de 5 554 discours datant de 2001 à 2025 a été réalisée. Elle prouve l'importance de la guerre dans les discours présidentiels de manière générale, mais aussi l'importance croissante de son vocabulaire avec le temps. La cooccurrence de la guerre avec d'autres thématiques se distingue comme un phénomène marquant depuis 2017-2018. Ces résultats justifient la poursuite du travail dans le cadre d'un projet à part entière, et appellent l'utilisation de méthodes plus avancées comme l'analyse de réseau.

Mots-clés : analyse de discours, rhétorique guerrière, traitement automatique du langage, Président de la République française, 2001-2025

---

1. Introduction

1.A. Sujet de recherche

« *Nous sommes en guerre* ». Le lundi 16 mars 2020, le Président de la République française s'exprimait en ces termes dans une allocation télévisée[1]. Il ne parlait cependant pas d'un conflit contre une autre nation, mais d'une pandémie qui touchait alors son pays. Le mot guerre sera finalement prononcé pas moins de 7 fois dans ce discours dit de « *guerre sanitaire contre le coronavirus* ».

Depuis la pandémie de 2020, l'utilisation de la rhétorique de guerre dans les discours présidentiels français semble s'être multipliée. Le Président a ainsi appelé à un « *réarmement démographique* » au sujet de la natalité[2], à l'établissement d'un nouveau service militaire volontaire au sujet de la jeunesse[3], ou bien à « *l'augmentation de l'effort de défense* » au sujet du budget[4]. Ses prédécesseurs ont eux aussi connu des crises par le passé, comme par exemple François Hollande en 2015 face à des attentats terroristes, Nicolas Sarkozy en 2008 face à une crise financière, et Jacques Chirac après les attentats du 11 septembre 2001. Pourtant, ils ne semblent pas avoir eu le même rapport avec le vocabulaire de la guerre. Dans le cadre de la Ve République, le Président français est le chef des armées. Il préside les conseils et les comités supérieurs de la défense nationale. Il est également la « clé de voûte des institutions », au sens où il nomme le premier ministre, possède la capacité de dissolution de l'Assemblée nationale, et dispose de la légitimité du suffrage universel direct[5]. Le choix de ses mots peut donc traduire l'orientation des politiques nationales. Dans un contexte de hausse générale des tensions internationales, une étude diachronique, mobilisant les méthodes computationnelles, et portant sur les 4 derniers Présidents de la République, pourrait éclairer d'une manière nouvelle la militarisation du discours politique.

1.B. Cadre théorique

Mobiliser l'analyse de discours pour expliquer la politique n'est pas une approche qui va de soi. Le professeur de sociologie Christian Le Bart explique ainsi dans *Le discours politique*[6] que les discours sont le

---

1. Macron E. (16 mars 2020). *Déclaration de M. Emmanuel Macron, président de la République, sur la mobilisation face à l'épidémie de COVID-19, la guerre sanitaire contre le coronavirus et sur les nouvelles mesures adoptées (report du 2e tour des municipales, suspension des réformes en cours, restrictions de déplacement...), Paris, le 16 mars 2020.*
2. Macron E. (16 janvier 2024). *Conférence de presse de M. Emmanuel Macron, président de la République, sur les priorités du nouveau gouvernement en matière d'école, d'ordre public, d'économie, de natalité, d'égalité des chances, d'écologie, de services publics et de santé, à Paris le 16 janvier 2024.*
3. Macron E. (27 novembre 2025). *Déclaration de M. Emmanuel Macron, président de la République, sur le Service national et la politique de la défense, à la 27e Brigade d'Infanterie de Montagne (BIM) de Varces le 27 novembre 2025.*
4. Macron E. (15 janvier 2026). *Déclaration de M. Emmanuel Macron, président de la République, sur la politique de défense de la France, à la base aérienne 125 d'Istres-Le Tubé " sous-lieutenant Charles Monier " le 15 janvier 2026.*
5. Constitution du 4 octobre 1958.
6. Le Bart, C. (2009). *Le discours politique*. Presses Universitaires de France. https://doi.org/10.3917/puf.lebar.1998.01.

produits à la fois de déterminants sociaux et de stratégies individuelles. Du point de vue des acteurs, le rôle des discours serait donc essentiellement symbolique, participant à la construction de la réalité de manière discursive. En outre, Patrick Charaudeau explique dans *Le discours politique : Les masques du pouvoir*[7] que la stratégie discursive de l'orateur est contrainte par le cadre social de la prononciation du discours. Ses mots s'adaptent aux attentes du public, et son attitude correspondrait à une mise en scène prédéterminée. Concernant les Présidents, ces derniers devraient ainsi s'inscrire dans un *ethos* partagé, forme de masque leur imposant certaines attitudes et certains mots. Cela justifierait une minimisation des stratégies discursives individuelles, pour s'intéresser davantage à l'évolution sémantique des mot, en fonction des contextes politiques internes et externes à la France. Du point de vue des mots, deux paradigmes complémentaires s'offrent à nous parmi les théories du discours politique. D'un côté, certains défendent l'idée selon laquelle les mots sont des *signifiants vides* qui peuvent être investis librement par les acteurs. Par leur stratégie discursive les orateurs peuvent infuser une certaine signification idéologique qui servent leur projet politique. C'est la théorie de Chantal Mouffe et Ernesto Laclau[8]. De l'autre côté, certains défendent l'idée selon laquelle les mots imposent un sens prédéterminé aux discours. Leur mobilisation produit un cadre cognitif univoque. C'est la théorie de George Lakoff et Mark Johnson[9]. Ces derniers ont d'ailleurs beaucoup travaillé sur la guerre, expliquant que la mobilisation de métaphores guerrières par les Présidents états-uniens a pu légitimer leur politique extérieure dans les années 1990-2000[10]. Si les mots peuvent être des *signifiants vides*, la guerre reste un cadre cognitif extrêmement contraignant.

Pour notre réflexion, la guerre dans les discours présidentiels français relèverait donc d'une stratégie discursive, investissant des thématiques *vides* – au sens de Laclau et Mouffe – pour y imposer le cadrage cognitif contraignant de la guerre. Cependant, cette stratégie s'inscrit dans un contexte politique national et international, ainsi que dans un certain *ethos* présidentiel qui déterminent son énonciation. L'apparition de la guerre seule n'aura donc pas très grande importance, il faudra regarder son occurrence au regard du contexte sémantique de la phrase (est-ce qu'on parle de démographie ? D'économie ? De l'environnement?). L'identité exacte du Président sera également secondaire. C'est davantage le contexte politique du moment (sommes-nous après les attentats de 2015 ? Après l'invasion de l'Ukraine par la Russie?) qui nous intéressera. À ce titre, nos unités d'analyse privilégiées serons le temps et la cooccurrence de la guerre avec d'autres sujets.

Il existe plusieurs manières d'analyser des discours. Nous nous baserons sur l'ouvrage de Céline Poudat et Frédéric Landragin « *Explorer un corpus textuel : Méthodes – pratiques – outils* »[11] pour définir notre approche. D'abord elle peut être qualitative ou bien quantitative. L'approche qualitative s'intéresse au cadre d'apparition d'un phénomène discursif, tandis que l'approche quantitative s'intéresse à la caractérisation du corpus et l'extraction d'observations. Ensuite, elle peut être fondée sur le corpus ou bien guidée par le corpus. L'analyse fondée sur le corpus vise à tester des hypothèses à partir des textes, elle de nature déductive. L'analyse guidée par le corpus vise à faire émerger le processus de problématisation et d'expérimentation à partir de l'exploration des textes, elle est de nature inductive. Dans le cadre de cette recherche, nous aurons une approche plutôt déductive. Nous souhaitons confirmer notre première impression selon laquelle la guerre est de plus en plus utilisée dans les discours et associée à de nouvelles thématiques. En ce sens, l'analyse sera fondée sur le corpus, car nos hypothèses sont déjà formulées. Notre recherche sera donc quantitative.

Un enjeu de ce projet de recherche est l'apprentissage et l'utilisation du langage de programmation *Python*. Cet apprentissage sera basé sur l'ouvrage « *Python pour les SHS : Introduction à la programmation pour le traitement des données* »[12] d'Émilien Schultz et Matthias Bussonnier. Le traitement automatique du langage sera sera spécifiquement étudié via le manuel « *Traitement automatique du langage naturel avec Python : Le NLP avec SpaCy et NLTK* »[13] de Benoît Prieur. Étant donné que ce projet est mené intégralement en autonomie et sans supervision, l'intelligence artificielle sera mobilisée pour l'identification des erreurs de programmation. Deepseek a été choisi comme LLM de référence pour son accessibilité. Afin d'éviter que toute la programmation repose sur le LLM, chaque prompt contiendra la mention suivante : « *La réponse doit être formulée comme un cours de programmation, en expliquant le raisonnement plutôt qu'en écrivant le code directement. L'objectif est d'apprendre la programmation et non pas de recopier les réponses.* ».

---

7. Charaudeau P. (2005). *Le discours politique : les masques du pouvoir*. Paris. Vuibert. 255 pages.
8. Mouffe C. et Laclau E. (2009). *Hégémonie et stratégie socialiste*. Solitaires intempestifs. Expériences philosophiques. 336 pages.
9. Lakoff G. et Johnson M. (1980). *Metaphors we live by*. University of Chicago Press. 242 pages.
10. Lakoff G. (1991). Metaphor and war : the metaphor system used to justify war in the gulf. Peace Research. Vol 23. pp. 25-32. https://www.jstor.org/stable/23609916
11. Monte, M. (2018). Céline Poudat et Frédéric Landragin. *Explorer un corpus textuel. Méthodes – pratiques – outils*. Louvain-la-Neuve et Paris, De Boeck Supérieur, 2017. Mots. Les langages du politique, 116(1), 145-148.
12. Schultz É., Bussonnier M. (2021). *Python pour les SHS : Introduction à la programmation pour le traitement des données*. Presses Universitaires de Rennes. Éd. 2023.
13. Prieur B. (2024). *Traitement automatique du langage naturel avec Python – Le NLP avec spaCy et NLTK*. Eni Editions.

Dans la littérature traitant des discours présidentiels, le travail de Damon Mayaffre se distingue des autres. Ce chercheur en histoire et en linguistique est spécialiste des discours politiques et présidentiels. Il mobilise dans ses différents travaux les méthodes de traitement des corpus numériques (logométrie, ADT, deep learning), ce qui correspond à aux objectifs de ce projet. À ce titre, « *Le discours présidentiel sous la Ve République. Chirac, Mitterrand, Giscard, Pompidou, De Gaulle* »[14] et ses autres ouvrages[15] ont été précieux pour guider notre travail. En effet, il existe plusieurs approches quantitatives des discours présidentiels. On peut d'abord chercher à distinguer les styles personnels de chaque président, ce qui n'est pas notre approche. On peut également analyser des mots spécifiques, des expressions ou des tournures de phrase à travers le temps, ce qui nous intéresse davantage. Damon Mayaffre insiste sur l'utilisation de la cooccurrence comme unité d'analyse[16]. Effectivement, la cooccurrence pallie l'ambiguïté de certains mots ou de leur utilisation (par exemple, la valeur travail dans les discours d'Arlette Laguiller n'est pas celle de Nicolas Sarkozy en 2007). Notre travail s'aligne avec ces réflexions. L'objectif sera d'étudier l'évolution du langage présidentiel à travers le temps, indépendamment des styles individuels. L'objet d'étude sera la rhétorique guerrière, l'observation cooccurrentielle de la guerre avec d'autres sujets sera quant à elle l'unité d'analyse visée pour le projet final.

1.C. Problématisation

Notre question initiale porte sur le tournant sémantique supposé des discours présidentiels français. La guerre semble apparaître davantage, et elle semble de plus en plus associée à des sujets qui lui sont extérieurs (santé, démographie, culture…). Notre cadre analyse vise à expliquer quantitativement ce tournant par la cooccurrence à travers le temps. Cependant, à ce stade de la réflexion, nous ne savons pas si la présence de guerre est bel et bien croissante dans les discours, mais également davantage associée à d'autres thématiques, ni depuis quand. L'enjeu de cette recherche exploratoire sera donc d'objectiver l'évolution de la guerre dans les discours présidentiels français, et de déterminer un tournant, en vue d'un futur mémoire : *la guerre est-elle réellement de plus en plus présente dans les discours présidentiels français ?*

Plusieurs hypothèses s'imposent :

• **Hypothèse 1 (importance générale)** : La guerre est un sujet important dans les discours présidentiels français comparé à d'autres thématiques.
• **Hypothèse 2 (importance croissante)** : La guerre est un sujet qui devient de plus en plus important avec le temps dans les discours présidentiels.
• **Hypothèse 3 (expansion de l'importance)** : La guerre est de plus en plus associée à d'autres thématiques dans les discours.

À nos yeux, une étude approfondie du sujet sera justifiée à partir du moment où ces trois hypothèses se confirment.

1.D. Méthodologie

Le travail préliminaire de recherche se basera sur un corpus initial de 5 554 discours présidentiels français, aspirés par *web-scraping* depuis le site internet *Vie-Publique*[17], à partir de l'extension de navigateur « *Web Scraper* ». Cette extension aspire des données présélectionnées via simple clic. Les bornes temporelles du corpus ont été fixées du 11 septembre 2001 au 31 décembre 2025. Ces dates ont été choisies car elles marquent la fin d'une période d'hégémonie états-unienne sur les relations internationales suite à la chute de l'URSS en 1991, et incluent un maximum d'années complètes jusqu'à nos jours. Une étude sur 25 ans permettra ainsi de fixer dans le temps long un moment de bascule concernant le vocabulaire de la guerre. Il faut noter ici le caractère institutionnel de notre corpus, qui est issu d'un site rattaché aux services du Premier ministre et de la *Direction de l'Information Légale et Administrative* (*DILA*)[18]. En ce sens, les discours proposés sont potentiellement biaisés, car ils sont uniquement énoncés dans des cadres formels, et ne représentent pas l'ensemble de l'activité discursive des Présidents. Cependant, un tel corpus est idéal pour

14. Mayaffre D. (2012). *Le discours présidentiel sous la Vème République. Chirac, Mitterrand, Giscard, Pompidou, De Gaulle*. Paris. Presses de Sciences Po. 2012. 384 pages
15. Cf. Mayaffre D. (2012). *Mesure et démesure du discours. Nicolas Sarkozy (2007-2012)*. Paris. Presses de Sciences Po. 2012. 368 pages. Ou encore Mayaffre D. (2021). *Macron ou le mystère du verbe. Ses discours décryptés par la machine*. La Tour-d'Aigues. Éditions de l'Aube. 2021. 343 pages.
16. Mayaffre D. (2014). *Plaidoyer en faveur de l'Analyse de Données co(n)Textuelles. Parcours cooccurrentiels dans le discours présidentiel français (1958-2014)*. JADT. Paris. pp. 15-32.
17. Lien fourni en annexe
18. Vie-Publique (Consulté le 1er mars 2026). *Qui sommes-nous ?*. https://www.vie-publique.fr/qui-sommes-nous

notre cadre théorique fondé sur l'*ethos* présidentiel : nous avons à traiter des déclarations formelles et ritualisées. Ce qui nous intéresse est justement cette parole « officielle » et son glissement sémantique. Si nous devions le caractériser, il faudrait dire que notre objet est un corpus institutionnel nativement numérisé[19].

Le corpus a été nettoyé et normalisé avec le langage de programmation *Python*, sur l'application web *Jupyter notebook,* à l'aide de la bibliothèque de traitement du langage *SpaCy*. Les discours sans date ou sans contenu ont été retirés du corpus. Le texte a été mis en minuscules. Les mots vides comme « le », « du » ou « mes » ainsi que la ponctuation ont été retirés. Le texte a ensuite été *tokenisé* (les mots ont été isolés les uns des autres). Les mots restants ont été *lemmatisés*, c'est-à-dire que le pluriel et le féminin ont été transformés en forme dites « neutres ». Le corpus n'a pas fait l'objet de *racinisation*, qui aurait permit de rendre le traitement du texte plus rapide et d'uniformiser davantage certains mots proches les uns des autres. Ce rejet s'explique par l'ambiguïté intellectuelle de la *racinisation* à notre niveau d'apprentissage de la programmation. L'analyse des données aurait été plus complexe et aurait nécessité un encadrement formel par un enseignant spécialisé. Rappelons tout de même que toute segmentation ou réduction des dimensions du texte peuvent être contestées épistémologiquement, et elles l'ont été dans la littérature[20]. Le traitement automatique du langage reste en tout cas une simplification du monde social.

À l'issue du nettoyage, il reste finalement 5 521 discours dits « normalisés ». Depuis 25 ans, le nombre moyen de discours par an est de 214,8 avec un écart-type de 77,56 discours. L'année comprenant le plus de discours est l'année 2013 (n = 332). L'année avec le moins de discours est l'année 2001 (n = 89) ce qui s'explique par la date de début de notre corpus fixée au 11 septembre 2001. L'année complète comportant le moins de discours est l'année 2022 (n = 111). De manière générale, les 10 années comportant le moins de discours présidentiels sont des années placées sous un mandat d'Emmanuel Macron (8 années sur 10). Emmanuel Macron et Nicolas Sarkozy sont les Présidents les plus sous-représentés dans notre corpus (respectivement 23 % et 22 % des discours parmi 4 Présidents). François Hollande est le plus sur-représenté dans notre corpus (29 %) et Jacques Chirac représente 26 % des discours prononcés depuis le 11 septembre 2001. Considérant notre cadre théorique, ainsi que le caractère institutionnel de notre corpus, l'identité de l'orateur importera peu dans la suite de notre analyse. Il s'agira plutôt d'étudier un *ethos* commun et son évolution sémantique depuis 25 ans.

Nous étudierons d'abord l'occurrence générale du lexique de la guerre comparé à d'autres thématiques. Cela impliquera la construction de lexiques d'analyse appropriés et la comparaison de leur occurrence annuelle via une anova. Nous observerons ensuite l'évolution du sujet à travers le temps à l'aide de l'indicateur TF-IDF. Cet indicateur permet de démontrer la saillance discursive d'un mot ou d'une thématique. Nous y reviendrons. Enfin, nous traiterons la cooccurrence de la guerre. Nous mesurerons l'apparition conjointe de nos différents lexiques dans une fenêtre prédéfinie puis comparerons l'évolution temporelle de celles-ci. Une anova permettra de déterminer les lexiques les plus influencées par la guerre. L'analyse finale agrégera les différentes cooccurrences à travers le temps via une analyse temporelle unique. L'ensemble de ces éléments ont pour objectif de démontrer l'importance croissante et l'expansion thématique de la guerre dans les discours présidentiels français. À l'issue de cette démonstration, nous proposerons plusieurs pistes d'approfondissement pour un mémoire à part entière. L'ensemble des données récoltées, du code produit et des résultats graphiques seront mis à disposition sur *Github*[21].

---

2. Résultats

2.A. L'importance de la guerre comparé à d'autres thématiques

Les premiers résultats obtenus via l'analyse de discours tendent à démontrer que la guerre est un sujet discursif important dans les discours présidentiels comparé à d'autres thématiques. On peut le démontrer en comparant la variance annuelle des occurrences pour 10 000 mots de 9 thématiques. Les 9 thématiques sélectionnées pour l'analyse sont la santé *(1)*, la démographie *(2)*, le social *(3)*, l'économie *(4)*, la culture *(5)*, l'environnement *(6)*, l'éducation *(7)*, la technologie *(8)* et la guerre *(9)*. Chacune de ces catégories inclut 10 mots jugés représentatifs.

19. *Beaudouin V. (2024). Corpus numériques : enjeux de délimitation, d'archivage et d'analyse*. Le Corpus : Corps à corps. https://doi.org/10.58282/colloques.12136
20. *Cf.* Poudat C. et Landragin F. *Op. cit.*
21. https://github.com/Gaspard-LeDu/portfolio

Figure 1

Lexique des thématiques analysées (10 mots par thématique)

Thématique	Lexique
Santé	"santé", "sanitaire", "soin", "soignant", "médecin", "médical" "hygiène", "maladie", "vaccin", "médicament"
Démographie	"démographie", "démographique", "naissance", "natalité", "enfant", "vieillissement", "génération", "fécondité", "mortalité", "population"
Social	"social", "société", "solidarité", "assistance", "famille", "familial", "jeunesse", "retraite", "chômage", "âge"
Économie	"économique", "croissance", "développement", "inflation", "budget", "financement", "investissement", "salaire", "capital", "profit"
Culture	"culture", "culturel", "identité", "identitaire", "valeur", "tradition", "héritage", "civilisation", "histoire", "artistique"
Environnement	"environnement", "nature", "biodiversité", "biosphère", "climat", "climatique", "environnemental", "écologie", "écologique", "naturel"
Éducation	"éducation", "université", "éducationnel", "enseignant", "élève", "professeur", "diplôme", "baccalauréat", "master", "enseignement"
Technologie	"technologie", "technologique", "innovation", "numérique", "spatial", "digital", "robotique", "informatique", "automatisation", "ordinateur"
Guerre	"guerre", "paix", "sécurité", "mobilisation", "réarmement", "armée", "conflit", "mobiliser", "front", "bataille"

Figure 2

ANOVA : variance annuelle de l'occurrence moyenne pour 10 000 mots de 9 thématiques (parmi un lexique de 10 mots chacune). Dans les discours présidentiels français depuis le 11 septembre 2001

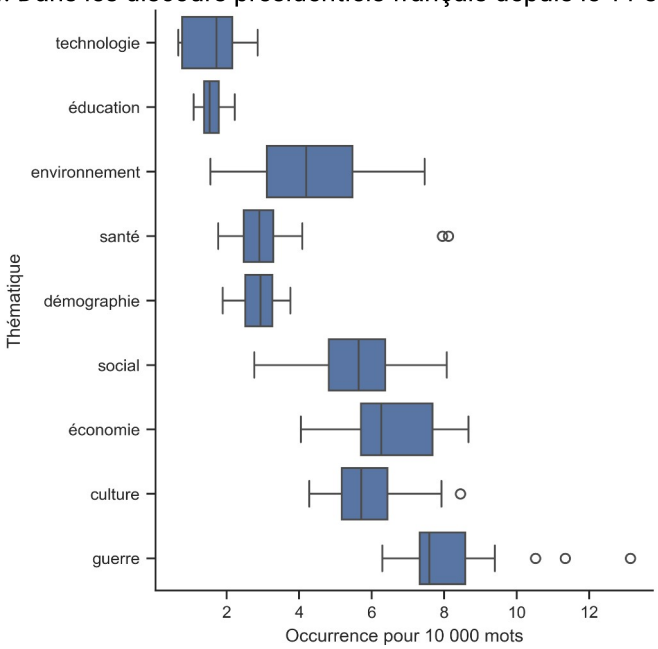

F-value = 91,43
p-value = 4,64e-65
Kruskal-Wallis H = 178,48 ; p-value < 0,001

Note de lecture – La guerre est la thématique qui apparaît en moyenne le plus pour 10 000 mots dans les discours présidentiels français chaque année depuis le 11 septembre 2001, atteignant en moyenne presque 8 occurrences pour 10 000 mots parmi un lexique de 10 mots. Sa valeur moyenne annuelle minimale (~6) dépasse la valeur moyenne de toutes les autres thématiques.

La thématique de la guerre tend à beaucoup apparaître en moyenne pour 10 000 mots, comparé aux autres thématiques analysées à nombre de mots égal. En outre, on peut affirmer que cette différence est significative (p = 4,64e-65, inférieur au seuil conventionnel 0,05[22]). Cependant la variance inter-lexicale est suspectement élevée (F-value = 91,43, nettement supérieur au seuil conventionnel 3,5), indiquant qu'il faut prendre nos résultats avec précaution, même si les tests non paramétriques confirment la tendance (Kruskal-Wallis, H = 178,48). Il faut également noter que nos valeurs sont des moyennes, et donc que le lexique de la guerre n'apparaît pas nécessairement 8 fois pour 10 000 mots dans chaque discours. Si la guerre est une thématique qui apparaît significativement plus que les autres, l'ordre de grandeur mériterait

22. *Cf.* Smith M. (2024). *Statistical Analysis Handbook : A Comprehensive Handbook of Statistical Concepts, Techniques and Software Tools*. The Winchelsea Press.

donc d'être affiné. Enfin, le choix des mots pour les lexiques de nos thématiques peut être jugé trop arbitraire. Rien ne garantit la parfaite équivalence entre nos 10 mots de la guerre et nos 10 mots de la santé. Une meilleure analyse inclurait davantage de mots, ou bien contrôlerait l'ensemble des mots prononcés toutes choses égales par ailleurs. Nous nous en tiendrons donc à conclure ici que la guerre est un thème important dans les discours présidentiels français, qui tend à être plus présent que les autres thématiques ces 25 dernières années. L'hypothèse 1 d'importance générale de la guerre dans les discours présidentiels français est confirmée.

2.B. L'importance croissante de la guerre dans les discours présidentiels

Notre deuxième hypothèse affirme que la guerre devient de plus en plus importante dans les discours présidentiels français depuis le 11 septembre 2001, et a priori depuis 2020. Un indicateur robuste pour mesurer le caractère saillant ou non d'un sujet est le score TF-IDF. Issu de l'anglais « *term frequency-inverse document frequency* », le TF-IDF mesure l'importance d'un terme contenu dans un document, relativement à une collection ou un corpus. Le score varie en fonction du nombre d'occurrence dans un document, rapporté au nombre de mots dans le document, ainsi que de la fréquence d'apparition du terme dans le reste du corpus. Un score élevé traduit à la fois une fréquence élevée dans le ou les documents, mais aussi un caractère saillant vis-à-vis du reste du corpus. Un autre indicateur pertinent aurait pu être le calcul des spécificités de Lafon. Cet indacteur permet lui aussi de quantifier l'importance d'un mot relativement au reste du corpus[23]. Cependant, dans le cadre d'un apprentissage autonome, le TF-IDF s'est révélé comme l'indicateur le plus accessible et le plus enseigné dans les manuels de programmation[24]. En outre, sa capacité à démontrer la saillance d'un mot au sein de larges corpus, fait de cet indicateur un outil adapté pour nos 5 521 discours. Afin d'améliorer l'analyse, nous avons étendu le lexique de la guerre à 20 mots au lieu de 10 : "guerre", "paix", "sécurité", "mobilisation", "réarmement", "armée", "conflit", "menace", "mobiliser", "défense", "front", "attaquer", "bataille", "attaque", "riposte", "déploiement", "stratégique", "tactique", "combattre", "combat". Le score mobilisé dans la figure 3 représente la valeur TF-IDF moyenne par discours de l'ensemble du lexique chaque année. Il indique une augmentation significative et élevée du score TF-IDF du lexique de la guerre au fil des années dans les discours présidentiels français.

Figure 3

TF-IDF : score TF-IDF moyen par discours du lexique de la guerre chaque année dans les discours présidentiels français depuis le 11 septembre 2001 (parmi un lexique de 20 mots)

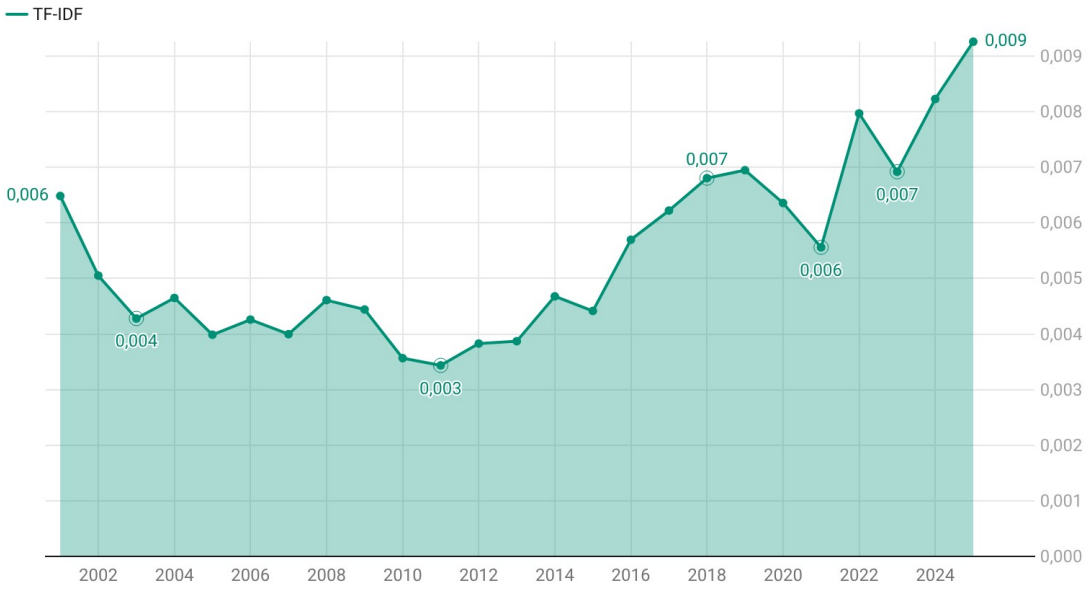

Note de lecture - Après être resté sous le seuil TF-IDF = 0,005 de 2002 à 2015, le score moyen par discours annuel du lexique de la guerre augmente jusqu'à atteindre 0,007 en 2019. Un deuxième pic est atteint en 2022 (TF-IDF = 0,008). En 2025, le score TF-IDF atteint son score le plus élevé depuis 25 ans (TF-IDF = 0,009)

Graphique: Gaspard Le Du (2026) • Source: Vie-Publique • Créé avec Datawrapper

r = 0,697
p-value < 0,0001

Comme expliqué en note de lecture, l'année 2015 semble représenter une rupture. Cependant les tentatives d'analyse de rupture par série temporelle n'ont pas abouti dans nos recherches. Une explication possible est

23. Mayaffre, D., Pincemin, B. et Poudat, C. (2019). *Explorer, mesurer, contextualiser. Quelques apports de la textométrie à l'analyse de discours*. Langue française, 203(3), 101-115. https://doi.org/10.3917/lf.203.0101.
24. *Cf.* Prieur B. *O.p. cit.*

le manque d'individus (seulement 25 années traitées). L'analyse de la corrélation montre de manière générale qu'il y a une augmentation positive forte (r = 0,70 considéré comme forte en sciences politiques[25]) et significative (p-value < 0,0001) du score TF-IDF du lexique de la guerre à travers le temps. Cela prouve que la guerre est une thématique qui devient significativement importante dans les discours présidentiels français, a priori à partir de 2015, puis 2022 et 2025. Ces dates pourraient correspondre à des évènements marquants, comme les attentats terroristes qui ont touché le pays en 2015 et l'agression russe contre l'Ukraine en 2022. L'année 2025 pose question, étant donné le manque de recul concernant cette date à l'heure actuelle. L'hypothèse 2 d'importance croissante de la guerre est elle aussi confirmée.

2.B. L'expansion de la guerre à d'autres thématiques

Notre troisième hypothèse affirme que la guerre est de plus en plus associée à d'autres thématiques au fil du temps. Pour le tester, nous avons mesuré la cooccurrence du lexique de la guerre avec les lexiques précédemment identifiés. Il est important de ne pas confondre les notions de cooccurrence et de collocation. Tandis que la première peut-être mesurée sur une fenêtre prédéterminée de mots, la collocation correspond à une proximité minimale de deux mots : « pluie battante » ou « nuit noire » par exemple. Ici, nous mesurerons l'apparition conjointe de deux lexiques dans une fenêtre de 10 mots. Cela correspond au maximum d'amplitude généralement utilisé pour l'analyse des cooccurrences, la majorité des analyses se situant dans des fenêtres de 5 à 10 mots[26]. À chaque apparition d'un mot du lexique de la guerre, nous observerons si un mot du lexique cible apparaît dans les 10 mots le précédant ou les 10 mots le suivant. Cette méthode est plébiscitée pour l'analyse des discours présidentiels, notamment par Damon Mayaffre, qui explique ainsi que cette méthode permet de « *passer de la forme au sens* ». Tandis que l'analyse d'un mot seul peut être ambiguë (« classe »), l'étude de la cooccurrence peut quant à elle traduire directement le sens du discours (la cooccurrence du mot « classe » avec le mot « lutte » dans un discours politique, contre le mot « classe » et le mot « élève » dans un autre). Dans notre cas, l'analyse des cooccurrences inter-lexicales indique une expansion générale du lexique de la guerre vers d'autres thématiques au fil des années.

Figure 4

COOCCURRENCES : nombre de co-occurrence moyen par discours chaque année dans les discours présidentiels français depuis le 11 septembre 2001 (parmi le lexique de la guerre et un autre lexique désigné, échelles indépendantes).

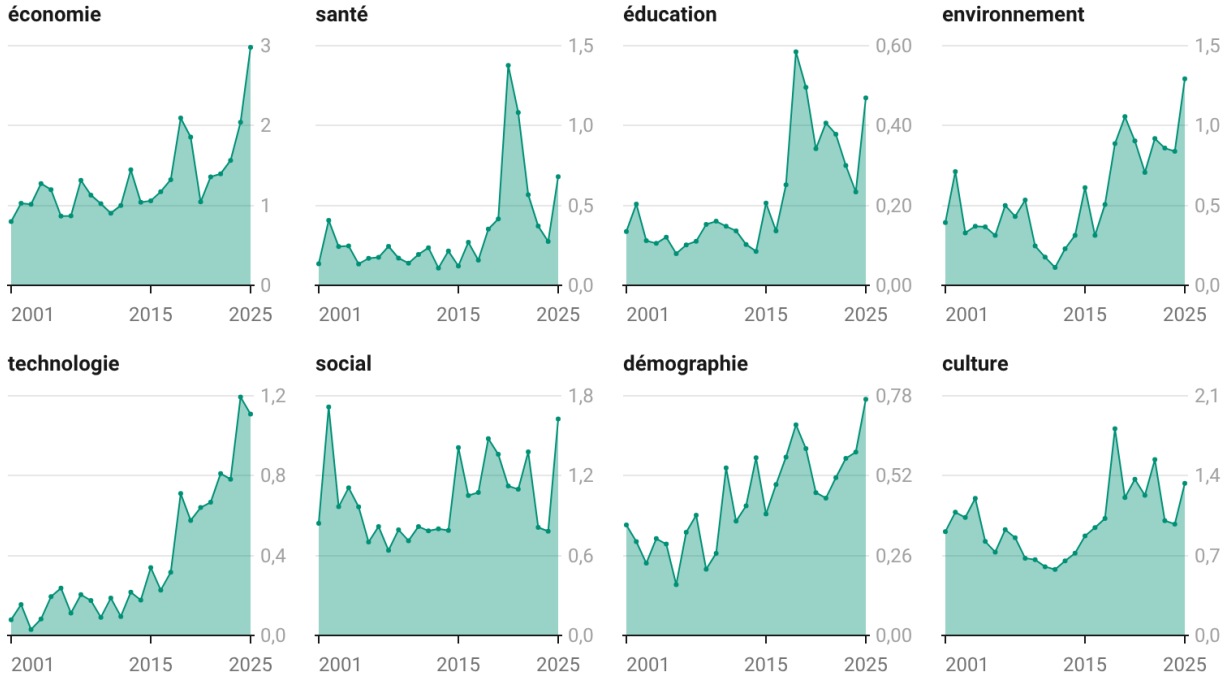

Note de lecture - Les thématiques de l'économie, de l'environnement, de la technologie et de la démographie connaissent toutes un pic moyen de cooccurrence par discours en 2024-2025. La santé et l'éducation ont quant à elles déjà connu un pic supérieur par le passé, respectivement en 2020 et en 2018. La cooccurrence moyenne de la culture avec la guerre augmente nettement à partir de 2018 mais stagne jusqu'à 2025, tandis que la cooccurence du social et de la guerre atteint en 2025 un niveau comparable avec l'année 2002.

Graphique: Gaspard Le Du (2026) • Source: Vie-Publique • Créé avec Datawrapper

25. *Cf.* Akoglu H. (2018). *User's guide to correlation coefficients*. National Library of Medicine.
26. *Cf.* Poudat C. et Landragin F. *Op. cit.*

Figure 5

CORRÉLATION : tests de corrélation entre le nombre moyen de cooccurrences par discours et le temps (8 thématiques)

	Technologie	Démographie	Éducation	Économie	Environnement	Santé	Culture	Social
Corrélation	0,87	0,79	0,7	0,67	0,66	0,51	0,44	*N. Sign.*
p-value	2,41E-08	2,11E-06	8,94E-05	0,0003	0,0003	0,01	0,03	0,19

Les figures 4 et 5 démontrent une hausse des cooccurrences de la guerre sur un ensemble de thématiques, avec une nuance pour le social. Les domaines de la technologie, de la démographie, de l'éducation, de l'économie et de l'environnement se démarquent par une corrélation positive forte (r > 0,65) et significative (p < 0,005). La technologie, la démographie et l'éducation observent les évolutions les plus importantes (respectivement r = 0,87, r = 0,79 et r = 0,70). Il est intéressant de noter certains pics précédant l'année 2025 : en 2020 pour la santé et 2018 pour l'éducation et la culture. En outre, il est curieux d'observer que le domaine du social a connu un pic de cooccurrence similaire à 2025 par le passé (année 2002), expliquant l'absence de relation significative (p = 0,19). Malgré certains pics faciles à expliquer (2020 pour la santé correspondrait à la pandémie), il serait intéressant de se pencher qualitativement sur l'année 2002 pour le social, et 2018 pour l'éducation et la culture. Tout comme la figure 2, nos résultats sont très élevés et mériteraient d'être questionnés. La significativité très élevé de certaines corrélations peut être expliquée par le nombre de mots par lexiques (10) et le nombre d'individus observés (25 ans). Cela rend nos résultats sensibles aux valeurs aberrantes. Cependant, sur presque l'ensemble des lexiques, l'hypothèse 3 d'expansion de la guerre à d'autres thématiques reste tendanciellement confirmée.

Figure 6

ANOVA : variance annuelle de la cooccurrence moyenne par discours sur 8 thématiques (parmi un lexique de 10 mots chacune). Dans les discours présidentiels français depuis le 11 septembre 2001

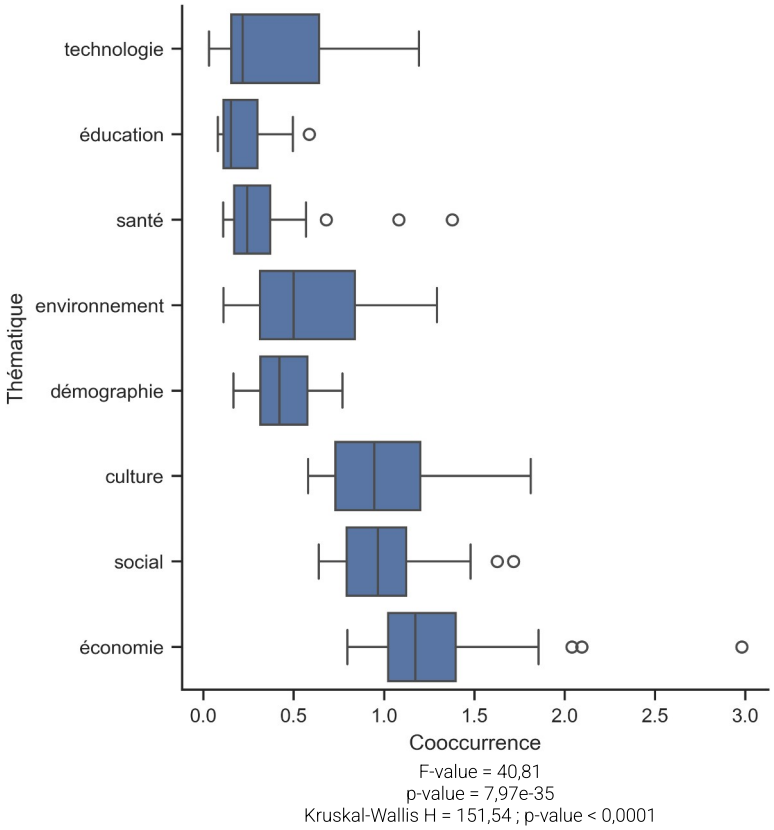

Note de lecture – L'économie, le social et la culture sont les thématiques qui cooccurrent en moyenne le plus avec la guerre dans les discours présidentiels français chaque année depuis le 11 septembre 2001, avoisinant en moyenne 1 cooccurrence par discours (parmi 8 lexiques de 10 mots). La démographie et l'environnement avoisinent quant à eux les 0,5 cooccurrences, tandis que la santé, l'éducation et la technologie restent sous la barre des 0,5 cooccurrences par discours en moyenne. Plusieurs valeurs aberrantes sont observées pour l'économie (3), le social (2), la santé (3) et l'éducation (1).

Alors que le social était la thématique qui avait le moins évolué avec le temps dans les figures 4 et 5, la figure 6 démontre qu'il s'agit en réalité d'une de celles qui cooccurrent en moyenne le plus avec la guerre (parmi les 8 lexiques étudiés), aux côtés de l'économie et la culture (évolution positive, modérée-forte, et significative pour ces deux thématiques). On remarquera une forte variance dans les domaines de la technologie, de l'environnement et de la culture. Plusieurs valeurs aberrantes apparaissent par ailleurs, rappelant des pics notables de cooccurrences observés temporellement (2020 pour la santé, 2002 pour le social…) mais sous-entendant aussi le caractère aberrant des certaines évolutions récentes du nombre de cooccurrences (2025 pour l'économie et le social). Le test de variance indique qu'il existe des différentes inter-thématiques significatives (p-value = 7,97e-35), mais encore une fois l'ordre de grandeur reste à préciser (F-value élevée = 40,81, confirmé par le test non paramétrique de Kruskal-Wallis H = 151,54). Enfin, on rappellera que nos valeurs sont des moyennes, signifiant qu'il n'y a pas nécessairement 1 coocurrence guerre/économie dans chaque discours. Les mêmes précautions que la figure 2 s'imposent. Le test permet cependant d'affiner l'hypothèse 3, en montrant quelles thématiques testées sont le plus associées à la guerre dans les discours présidentiels français (en l'occurrence l'économie, le social et la culture).

La dernière figure vise à illustrer la tendance générale des cooccurrences avec la guerre sur nos 8 thématiques. Il s'agit de la somme du nombre moyen de cooccurrences par discours chaque année sur l'ensemble des sujets étudiés.

Figure 7

COOCCURRENCES : somme du nombre moyen de cooccurrences avec la guerre chaque année dans les discours présidentiels français depuis le 11 septembre 2001 (parmi 8 thématiques)

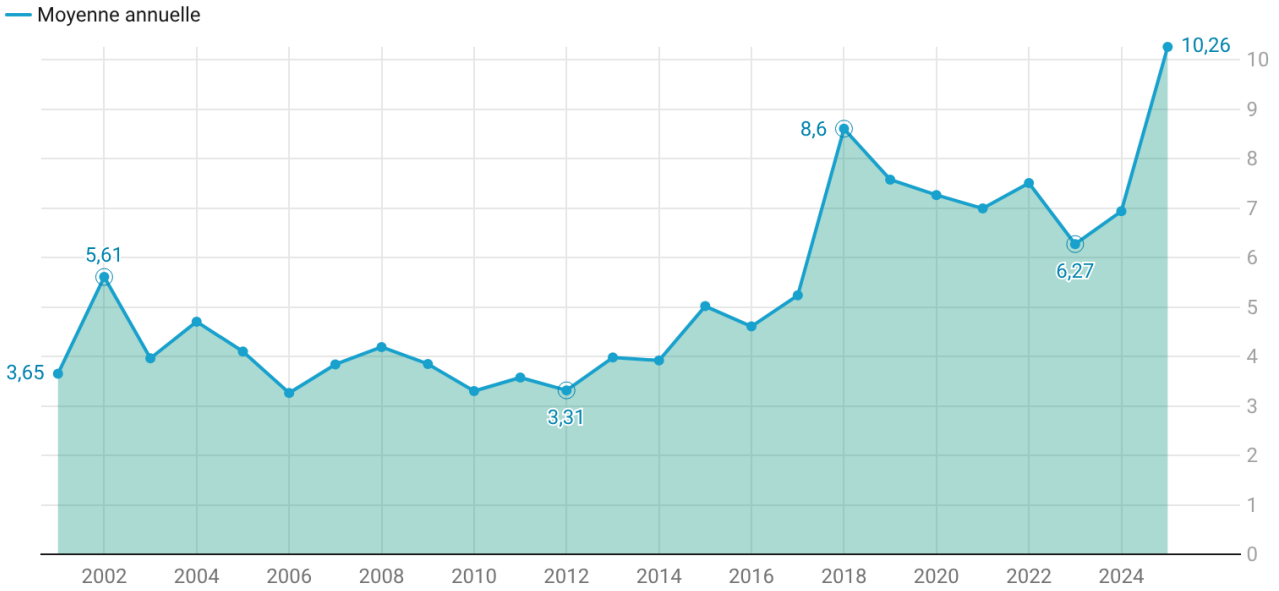

Note de lecture - Jusqu'en 2017 et mis à part un pic à 5,61 en 2002, le nombre moyen de co-occurrences avec la guerre parmi les 8 thématiques reste en dessous de 5 par discours. Le chiffre monte une première fois à 8,6 en 2018, puis demeure autour de 7 entre 2018 et 2024. Le nombre moyen de cooccurrences avec la guerre dans les discours présidentiels français atteint son plus haut niveau en 2025 avec plus de 10,26 associations en moyenne par discours.

Graphique: Gaspard Le Du (2026) • Source: Vie-Publique • Créé avec Datawrapper

r = 0,75
p-value = 1,88e-05

La figure 7 semble montrer un tournant à partir des années 2017-2018, au cours desquelles la somme du nombre moyen de cooccurrences par discours passe de 5 à 8,6. L'année 2025 est également l'année où le nombre moyen de cooccurrences est le plus élevé depuis le 11 septembre 2001 (10,26 par discours). La corrélation entre les cooccurrences et le temps est positive, forte (r = 0,75) et significative (p-value = 1,88e-05). L'ensemble de ces éléments montre une expansion générale de la guerre vers d'autres thématiques, a fortiori depuis 2017-2018. Cette date pourrait correspondre à l'arrivée au pouvoir du Président Emmanuel Macron (2017), mais aussi de Donald Trump aux États-Unis (2017). Il est intéressant de noter que les pics 2017-2018 et 2025 suivent tout deux des pics TF-IDF de la figure 3 (2015 et 2022). Il serait pertinent de vérifier si les pics de cooccurrences font bien suite à des pics TF-IDF de la guerre dans les discours présidentiels français. L'hypothèse 3 d'expansion de la guerre vers d'autres thématiques est confirmée d'un point de vue général.

3. Discussions

À l'issue de nos résultats, nous sommes en mesure d'affirmer que la rhétorique de guerre est effectivement un sujet important dans les discours présidentiels français depuis le 11 septembre 2001. Cette importance est significativement croissante avec le temps et s'étend à de nouvelles thématiques. L'ensemble de ces éléments vont dans le sens de nos hypothèses et répondent sans ambiguïté à notre question initiale : il y a bien un glissement sémantique significatif chez les Présidents français depuis plusieurs années. Dans le cadre de nos réflexions théoriques, cela reflète la capacité de la guerre à cadrer cognitivement les discours, en investissant des thématiques *vides* comme l'économie ou la culture. En outre, nous sommes en mesure d'identifier plusieurs dates clés potentielles. L'importance croissante de la guerre peut s'observer à partir de 2015, et accélère en 2022 puis en 2024-2025. Ces dates pourraient correspondre aux attaques terroristes qu'a subi la France en 2015, à l'agression russe contre l'Ukraine en 2022 et à la hausse des tensions internationales depuis quelques années. La pénétration de la guerre vers d'autres thématiques semble suivre sa prise d'importance, avec quelques années de délai : 2017-2018 puis 2025.

Cependant, ce travail se confronte à quelques limites. La plupart de nos analyses reposent sur la construction de lexiques thématiques à la fois limités (10 à 20 mots) et discutables (choix des mots difficile à objectiver à ce stade de la réflexion). Cela se traduit dans nos tests statistiques, donnant lieu à plusieurs valeurs aberrantes (valeur des F-values suspectes). Nos résultats représentent davantage des tendances que des valeurs absolues.

À ce titre, un travail plus poussé pourrait combler nos lacunes. D'emblée on pourrait imaginer le recours à des lexiques plus étendus et donc moins sensibles aux valeurs aberrantes. Une autre piste semble également être le recours à des méthodes plus poussées de traitement automatique du langage. Ainsi, le recours à des indicateurs appropriés pour mesurer la cooccurrence serait une première avancée. Il en existe deux : le *t-score* et l'information mutuelle. Ils permettent de rapporter la cooccurrence à l'occurrence isolée de chacun des mots[27]. On pourrait alors rendre la mesure plus robuste. Parmi toutes ces propositions, c'est surtout l'analyse de la poly-cooccurrence qui semble fondamentale pour la poursuite de cette recherche. Plutôt que d'analyser la guerre mot par mot ou bien lexique par lexique, il existe des méthodes pouvant mesurer les relations complexes de cooccurrences toutes choses égales par ailleurs. Par exemple, les analyses de réseau permettent d'observer directement l'ensemble des cooccurrences d'un mot[28]. Cela fournit des indicateurs supplémentaires qui pourraient enrichir la recherche dans une large mesure. On pourrait alors mesurer la centralité de la guerre dans le réseau de cooccurrence, déterminer les sujets cooccurrents les plus proches par l'identification de clusters, et voir les chemins discursifs les plus courts menant la guerre vers d'autres sujets. Cette approche a été notamment développée sous le nom de « cooccurrence généralisée » par Viprey[29], ayant lui-même travaillé sur des discours présidentiels avec Damon Mayaffre[30]. Selon l'avancée de l'analyse de réseau, l'utilisation du deep learning pourrait également être intéressante en dernière partie. Cela permettrait d'identifier des chemins de cooccurrence inter-thématiques privilégiés, prédire de nouvelles associations, et construire des « discours de guerre » futurs sur ces thématiques. L'ensemble de ces méthodes pourraient renforcer notre cadre théorique, en prouvant la capacité de cadrage cognitif de la guerre.

Une proposition annexe mais secondaire mérite d'être évoquée. Dans le cadre des discours de guerre, les relations internationales pourraient jouer un rôle non négligeable. À ce titre, l'intégration de discours étrangers à notre étude sous une forme ou une autre pourrait être pertinent. Les discours présidentiels états-uniens en particulier mériteraient d'être étudiés. En effet, leur importance sur les relations internationales sont indiscutables étant donné la place centrale de ce pays, a fortiori depuis la réélection de Donald Trump en 2024. Une analyse comparée de l'évolution discursive France / États-Unis pourrait être une piste d'étude très fructueuse. Cette analyse se justifierait en fonction la transférabilité du code produit jusqu'à présent à de nouveaux corpus, et de l'accessibilité de l'anglais à la fois techniquement (existence de nombreux outils de traitement automatique du langage) et linguistiquement (maîtrise avancée de l'anglais). L'enjeu pourrait être de recontextualiser l'évolution discursive de chaque pays concernant la guerre, au regard de leur histoire respective. Cependant, cette proposition doit être prise de manière annexe à l'analyse de réseau.

---

27. . *Cf.* Poudat C. et Landragin F. *Op. cit.*
28. *Ibid.*
29. *Viprey, J.-M. (2000). Hypertexte de corpus littéraire : cartographie et statistique multidimensionnelle. In : Actes des 5e Journées Internationales d'Analyse statistique des Données Textuelles (JADT 2000), Lausanne, pp. 535-539.*
30. Mayaffre D. (2012). *La coocurrence. Du fait statistique au fait textuel : présentation*. Corpus. N°11. pp. 7-19.

4. Conclusion

L'ensemble du travail exploratoire mené confirme notre questionnement initial. La militarisation des discours présidentiels français depuis le 11 septembre 2001 est un réel sujet. Cependant, certaines limites font que nos résultats traduisent plutôt des tendances, et non pas encore des valeurs absolues. En outre, certaines tendances identifiées posent davantage de questions qu'elles n'en résolvent. À ce titre la poursuite de ce travail à l'aide de nouveaux indicateurs et de nouvelles méthodes s'impose. L'analyse de réseau se distingue comme une piste privilégiée de recherche. Cependant, cette approche nécessiterait un encadrement approprié. Si l'apprentissage de Python en autonomie a été jusqu'à présent possible, la poursuite de ce travail dans le cadre d'un Master spécialisé dans les méthodes quantitatives permettrait d'accélérer la maîtrise des outils computationnels en sciences sociales, et de rendre la structuration du projet plus cohérente. Dans le cas annexe où la piste comparative serait jugée pertinente, le co-encadrement par un enseignant spécialisé dans la culture, société et vie politique états-unienne pourrait être précieuse. Ce travail aboutirait à la production d'un mémoire de fin d'études, et donnerait idéalement lieu à publication dans une revue scientifique. L'objectif étant de poursuivre une carrière académique en thèse et aux Pays-Bas.

Gaspard Le Du
Master 2 – Recherche et Expertise en Sciences Sociales du Politique
Sciences Po Rennes – ENS Rennes – EHESP

Bibliographie

Par ordre d'apparition :

[1] Macron E. (16 mars 2020). *Déclaration de M. Emmanuel Macron, président de la République, sur la mobilisation face à l'épidémie de COVID-19, la guerre sanitaire contre le coronavirus et sur les nouvelles mesures adoptées (report du 2e tour des municipales, suspension des réformes en cours, restrictions de déplacement...), Paris, le 16 mars 2020*. https://www.vie-publique.fr/discours/273933-emmanuel-macron-16-mars-2020-coronavirus-confinement-municipales

[2] Macron E. (16 janvier 2024). *Conférence de presse de M. Emmanuel Macron, président de la République, sur les priorités du nouveau gouvernement en matière d'école, d'ordre public, d'économie, de natalité, d'égalité des chances, d'écologie, de services publics et de santé, à Paris le 16 janvier 2024*. https://www.vie-publique.fr/discours/292703-emmanuel-macron-16012024-politique-gouvernementale

[3] Macron E. (27 novembre 2025). *Déclaration de M. Emmanuel Macron, président de la République, sur le Service national et la politique de la défense, à la 27e Brigade d'Infanterie de Montagne (BIM) de Varces le 27 novembre 2025*. https://www.vie-publique.fr/discours/301129-emmanuel-macron-27112025-service-national

[4] Macron E. (15 janvier 2026). *Déclaration de M. Emmanuel Macron, président de la République, sur la politique de défense de la France, à la base aérienne 125 d'Istres-Le Tubé " sous-lieutenant Charles Monier " le 15 janvier 2026*. https://www.vie-publique.fr/discours/301691-emmanuel-macron-15012026-politique-de-la-defense

[5] Constitution du 4 octobre 1958. https://www.conseil-constitutionnel.fr/le-bloc-de-constitutionnalite/texte-integral-de-la-constitution-du-4-octobre-1958-en-vigueur

[6] Le Bart, C. (2009). *Le discours politique*. Presses Universitaires de France. https://doi.org/10.3917/puf.lebar.1998.01.

[7] Charaudeau P. (2005). *Le discours politique : les masques du pouvoir*. Paris. Vuibert. 255 pages.

[8] Mouffe C. et Laclau E. (2009). *Hégémonie et stratégie socialiste*. Solitaires intempestifs. Expériences philosophiques. 336 pages.

[9] Lakoff G. et Johnson M. (1980). *Metaphors we live by*. University of Chicago Press. 242 pages.

[10] Lakoff G. (1991). *Metaphor and war : the metaphor system used to justify war in the gulf*. Peace Research. Vol 23. pp. 25-32. https://www.jstor.org/stable/23609916

[11] Monte, M. (2018). Céline Poudat et Frédéric Landragin, *Explorer un corpus textuel. Méthodes – pratiques – outils.* Louvain-la-Neuve et Paris, De Boeck Supérieur, 2017. Mots. Les langages du politique, 116(1), 145-148. https://doi.org/10.4000/mots.23101.

[12] Schultz É., Bussonnier M. (2021). *Python pour les SHS : Introduction à la programmation pour le traitement des données*. Presses Universitaires de Rennes. Éd. 2023. https://www.babelio.com/livres/Schultz-Python-pour-les-SHS/1294941

[13] Prieur B. (2024). *Traitement automatique du langage naturel avec Python – Le NLP avec spaCy et NLTK*. Eni Editions.

[14] Mayaffre D. (2012). *Le discours présidentiel sous la Vème République. Chirac, Mitterrand, Giscard, Pompidou, De Gaulle*. Paris. Presses de Sciences Po. 2012. 384 pages.

[15] Mayaffre D. (2012). *Mesure et démesure du discours. Nicolas Sarkozy (2007-2012)*. Paris. Presses de Sciences Po. 2012. 368 pages.

[16] Mayaffre D. (2021). *Macron ou le mystère du verbe. Ses discours décryptés par la machine*. La Tour-d'Aigues. Éditions de l'Aube. 2021. 343 pages.

[17] Mayaffre D. (2014). *Plaidoyer en faveur de l'Analyse de Données co(n)Textuelles. Parcours cooccurrentiels dans le discours présidentiel français (1958-2014)*. JADT. Paris. pp. 15-32.

[18] Beaudouin V. (2024). *Corpus numériques : enjeux de délimitation, d'archivage et d'analyse*. Le Corpus : Corps à corps. https://doi.org/10.58282/colloques.12136

[19] Smith M. (2024). *Statistical Analysis Handbook : A Comprehensive Handbook of Statistical Concepts, Techniques and Software Tools*. The Winchelsea Press. https://www.statsref.com/StatsRefSample.pdf

[20] Mayaffre, D., Pincemin, B. et Poudat, C. (2019). *Explorer, mesurer, contextualiser. Quelques apports de la textométrie à l'analyse de discours*. Langue française, 203(3), 101-115. https://doi.org/10.3917/lf.203.0101.

[21] Akoglu H. (2018). *User's guide to correlation coefficients*. National Library of Medicine. https://pmc.ncbi.nlm.nih.gov/articles/PMC6107969/

[22] Viprey, J.-M. (2000). *Hypertexte de corpus littéraire : cartographie et statistique multidimensionnelle*. In : *Actes des 5e Journées Internationales d'Analyse statistique des Données Textuelles (JADT 2000)*, Lausanne, pp. 535-539.

[23] Mayaffre D. (2012). *La coocurrence. Du fait statistique au fait textuel : présentation*. Corpus. N°11. pp. 7-19.

Annexe

Site internet Vie-publique :

https://www.vie-publique.fr/discours/recherche?search_api_fulltext_discours=&sort_by=field_date_prononciation_discour&field_intervenant_title=&field_intervenant_qualite=&field_date_prononciation_discour_interval%5Bmin%5D=2001-09-10&field_date_prononciation_discour_interval%5Bmax%5D=2026-01-01&field_type_emetteur%5B9340%5D=9340

Page Github du projet :

https://github.com/Gaspard-LeDu/portfolio